Principal component analysis

目的：suppress redundant information，保留主要的 scene variance

used to analyze multivariate data　　Reducing the Dimension of Multivariate Data.

应用：multichannel image processing（卫星图像处理）

卫星上的传感器

不同频谱下，综合成一张图片.

3 light spectrum　　4 infrared and thermal bands

visible

rectangular array of numbers

each number indicating the signal intensity

需要的背景知识：Diagonalization of Symmetric Matrices

Quadratic forms

Constrained Optimization

SVD

The "multidimensional" character of the data refers to the three spectral dimensions rather than the two spatial dimensions that naturally belong to any photograph.

空间的

PCA的第一步：中心化 使所有数据 have a zero mean.

然后计算 (sample) covariance matrix：$S = \frac{1}{N-1} BB^T$

$(BB^T)^T = BB^T$ = symmetric

Variance $= \frac{1}{n}\sum (x-\bar{x})^2$

Covariance $= \frac{1}{n}\sum (x-\bar{x})(y-\bar{y})$（两个变量之间的 Covariance）

当变量数量大于两个时，就需要用 covariance matrix 来描述，对角线为每个变量的方差.

$$\begin{bmatrix} Var(X) & Cov(X,Y) & Cov(X,Z) \\ Cov(Y,X) & Var(Y) & Cov(Y,Z) \\ Cov(Z,X) & Cov(Z,Y) & Var(Z) \end{bmatrix}$$

Total variance $= \sum Var = tr(S)$

对角线之和为总方差.

The sum of the diagonal entries of a square matrix S is called the trace of the matrix.

计算 covariance matrix 的第一步是中心化数据。

为什么关心方差和协方差？如果方差为0，那么这组数据是无变化的，没有任何信息可言. 闭眼去看一张像素点全部一样的图片，什么也看不出来.

如果要压缩数据（中心化之后的数据），二维只能变成一维（一条直线）

右图为二维数据，直觉告诉我们可以用一维来描述.

我们要找到这一个新的坐标轴 (first component).

每个数据点在这一个新坐标轴上的投影，可以代表它们，虽然损失了一些信息。

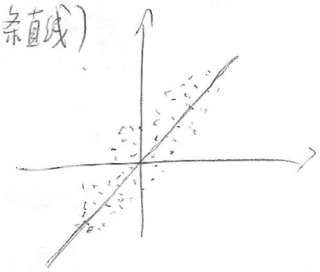

$R^2 \leftarrow X = \overset{2\times 2}{P}Y \rightarrow R^2$，我们要寻找 P，使得投影越分散越好.

糟糕的 P 只会让投影集中起来，无法区分数据点的投影（我们用投影来代表数据的）

因此，P 应该是使方差最大的线性变换. 我们已知 tr(S) 为总方差.

衡量 P，我们对比在 P 的线性变换之后，方差减少了多少

正交变换（旋转）不改变数据的总体方差. 数据还是那些数据，只不过用新视角去观察了. 新视角下将总方差的分布都集中在了 first component 下。这样，即使舍弃其它坐标轴，也能保留大部分方差。（物理角度：方差代表能量）

总体方差为何不变？方差本质是数据点的平方距离之和，PCA 改变的是视角，几何距离没有发生变化.

$X = PY$ $\quad \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix} = [u_1\ u_2 \dots u_p] \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_p \end{bmatrix}$ $\quad P = [u_1 \dots u_p]$: $p \times p$ orthongonal matrix.

(p-dimension) $\quad$ (p-dimension)

$u_1 \to$ first component, $u_2 \to$ second component.

The new variables $y_1, y_2 \dots y_p$ are uncorrelated and are arranged in order of decreasing variance.

为什么要找正交变换，而非任意变换呢？

定义：An orthogonal matrix is a square invertible matrix U such that $U^{-1} = U^T$ (whose columns and rows are orthonormal vectors)

P是orthogonal $\Rightarrow$ $P^{-1}x = Y$ (P^{-1}存在). 即 $P^TP = I$

Covariance $YY^T = P^{-1}x(P^{-1}x)^T = P^Tx(P^Tx)^T = P^Txx^TP$

$S \Rightarrow$ 原始的 covariance matrix. 对称

$S = p \times p$

目标是使 Y 的方差更集中在 first component.

这是一个优化问题.

~~Quadratic form~~.

PCA 本质上是一个带约束的 quadratic form 优化问题。

$X = PY \quad P^{-1}x = Y \quad P^Tx = Y \quad \begin{bmatrix} u_1^T \\ u_2^T \\ \vdots \\ u_p^T \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_p \end{bmatrix}$

$y_1 = u_1^T X = c_1x_1 + c_2x_2 + \cdots c_px_p$.

For any orthogonal matrix P, the covariance matrix of $Y_1, \dots Y_N$ (新的数据点坐标下) is P^TSP.

The desired orthogonal matrix P is one that makes P^TSP diagonal.

为什么要找到使 P^TSP diagonal 的 P？

假设只考虑 first principal component。我们只关心将要 projection 到的方向 u_1。只关心方向，所以取 $\|u_1\| = 1$ 单位向量。每个数据点在这个方向上的投影为 u_1^Tx

方差为 $\frac{1}{N}\sum\{u_1^Tx_n - u_1^T\bar{x}\}^2 \qquad \bar{x} = \frac{1}{N}\sum x_n$

$= \frac{1}{N}\sum\left(u_1^T(x_n - \bar{x})\right)^2$

$\cancel{= \frac{1}{N}\sum\langle u_1^T(x_n-\bar{x}), u_1^T(x_n-\bar{x})\rangle}$

$= \frac{1}{N}\sum u_1^T(x_n - \bar{x})\boxed{u_1^T(x_n - \bar{x})} \to$ 常量，转置后不变

$= \frac{1}{N}\sum u_1^T(x_n - \bar{x})(x_n - \bar{x})^T u_1$

$= \frac{1}{N}\sum u_1^T S u_1 \longrightarrow$ Quadratic form. 问题变成：如何选择 u_1 使其最大

$S = (x_n - \bar{x})(x_n - \bar{x})^T$: Covariance matrix.

PCR: principal components regression

When faced with a large set of correlated variables, principal components allow us to summarize this set with a smaller number of representative variables that collectively explain most of the variability in the original set.